Universidade Estadual de Campinas, Instituto de Computação (IC)
MC833A – Programação em Redes de Computadores

Professor Edmundo R. M. Madeira
Segundo Semestre de 2026

Projeto 3

Previsão de tráfego de rede com redes neurais recorrentes (LSTM)

A previsão do volume de tráfego é fundamental para o planejamento de capacidade, a detecção de anomalias e o balanceamento de carga em redes. Neste projeto você vai analisar e prever o tráfego de um link real de backbone, medido pelo projeto MAWI (WIDE, Japão), usando uma rede neural recorrente do tipo LSTM (*Long Short-Term Memory*).

Serão usados dois traces de 15 minutos, ambos de sábado, 10 de fevereiro, às 14:00 (horário do Japão), com 17 anos de diferença: 2007 (**200702101400**) e 2024 (**202402101400**). Você vai treinar um modelo para cada ano, testar cada modelo no seu próprio ano e também no outro ano, e comparar o tráfego de 2007 com o de 2024.

Dados

Os traces originais (arquivos PCAP) são grandes e demorados de processar, então já foram pré-processados e disponibilizados em arquivos Parquet compactos (séries temporais de bytes e pacotes, histogramas de tamanho de pacote, resumos etc.). Você não precisa baixar nem processar os PCAP.

Link para download da pasta do projeto: MC833A_2s_2026

Base de dados brutos (opcional)

- trace de 2007: https://mawi.wide.ad.jp/mawi/samplepoint-F/2007/200702101400.html
- trace de 2024: https://mawi.wide.ad.jp/mawi/samplepoint-F/2024/202402101400.html

Conteúdo da pasta

MC833A_T3_2026/
└── **notebooks/**
  ├── 01_EDA.ipynb (Parte 1: análise exploratória)
  ├── 02_LSTM.ipynb (Parte 2: modelamento preditivo)
  ├── 00_preprocessamento_MAWI.ipynb (opcional: mostra como os dados foram gerados; não é necessário executar)
└── **dados/**
  ├── **200702101400/** (trace de 2007)
  ├── **202402101400/** (trace de 2024)
  └── LEIAME_dados.md (descrição dos arquivos)

Configuração do ambiente (Google Colab)

Os notebooks foram feitos para rodar no Google Colab. Não é necessário GPU: as séries são pequenas e a CPU gratuita é suficiente.

1. Baixe a pasta do projeto pelo link acima.
2. Envie a pasta inteira para o seu Google Drive, mantendo a estrutura (sugestão: Meu Drive/MC833A_T3_2026/).
3. No Drive, abra o notebook com botão direito → Abrir com → Google Colaboratory (ou envie o .ipynbdiretamente ao Colab).
4. Quando a célula de setup executar **drive.mount**, o Colab pedirá permissão para acessar o seu Drive. É necessário autorizar o acesso; sem isso o notebook não consegue ler os dados.
5. Na primeira célula, confira a variável **PASTA_DADOS**. Se você usou exatamente Meu Drive/MC833A_T3_2026/dados, não precisa alterar nada; caso contrário, ajuste para o caminho da pasta dados no seu Drive.
6. Execute as células em ordem. Trabalhe na sua cópia dos notebooks (salvar uma cópia no Drive) para não perder o que já fez.

Requisitos

O projeto tem duas partes, cada uma em um notebook. As instruções detalhadas, os exemplos prontos e as dicas estão nos próprios notebooks; as células marcadas com `# TODO` são as que você deve completar.

Parte 1: Análise exploratória de dados (`01_EDA.ipynb`)

- **Gerar as estatísticas** descritivas do throughput por segundo (média, desvio-padrão, mínimo, quartis e máximo), para 2007 e 2024, separando tráfego total, TCP e UDP.
- **Produzir três gráficos**, cada um com 2007 e 2024 lado a lado: (1) throughput ao longo do tempo; (2) histogramas da distribuição do throughput de TCP e UDP; (3) distribuição do tamanho dos pacotes de TCP e UDP.
- **Comentar o que os resultados mostram** sobre a evolução do tráfego entre os dois anos.

Parte 2: Modelamento preditivo com LSTM (`02_LSTM.ipynb`)

- **Preparar a série de throughput:** dividir em treino (80%) e teste (20%) respeitando a ordem temporal, normalizar e criar janelas deslizantes (*look-back*) de 10 s; depois testar janelas de 20 s e 30 s para avaliar a sensibilidade ao tamanho do histórico.
- **Implementar a rede:** arquitetura enxuta com uma camada LSTM seguida de uma camada densa que prevê o próximo ponto da série. Ajustar e registrar os hiperparâmetros (épocas, *batch size*, tamanho da janela). Salvar o melhor modelo de cada ano.
- Treinar e avaliar com a métrica MSE (erro quadrático médio) no conjunto de teste.

- **Visualizar e analisar:** tabela de MSE por configuração de janela; gráfico real × previsto no conjunto de teste; comentários sobre os trechos de boa aderência e de desvios importantes (picos, períodos estáveis, variações rápidas).
- **Comparar 2007 e 2024:** montar a matriz modelo treinado em {2007, 2024} × testado em {2007, 2024}, e analisar o que acontece quando um modelo prevê o outro ano.

Discussão para o relatório

- Explicar por que os modelos tiveram o desempenho observado (rajadas de tráfego, estacionariedade, mudança de escala e de comportamento entre 2007 e 2024).
- Relacionar os resultados a fenômenos típicos de redes (picos de tráfego, comportamento periódico, possíveis anomalias).
- Apontar vantagens, limitações e sugestões de trabalho futuro.

Especificações

- **Linguagem:** Python, com TensorFlow/Keras (se preferir pode utilizar outro framework).
- **Ambiente:** Google Colab.
- **Reprodutibilidade:** fixar as sementes aleatórias (função `fixar_sementes` do notebook).
- **Código:** comentado e que permita a execução em ordem.
- **Dados:** não é necessário (nem recomendado) baixar ou versionar os arquivos PCAP.
- **Cuidado ao interpretar:** os dados vêm de um único ponto de medição, em um sábado à tarde, por 15 minutos. Evite generalizações como "a Internet de 2024 é assim".

Entregar

- **Relatório (PDF):** deve conter introdução, descrição geral, descrição dos dados e da abordagem, a seção **"Análise exploratória de dados"** (tabela de estatísticas, três gráficos e comentários), a seção **"Modelamento preditivo"** (descrição da abordagem LSTM, tabela de MSE por janela, gráfico real × previsto e análise), a comparação 2007 × 2024, a discussão crítica e a conclusão.

  Todas as figuras devem ter título, eixos com unidade e legenda.

- **Código:** os notebooks `01_EDA.ipynb` e `02_LSTM.ipynb` completados e executados (com as saídas visíveis).
- **Modelos:** os arquivos dos melhores modelos treinados de cada ano (`lstm_2007.keras` e `lstm_2024.keras`).

Datas de Entrega

10/11/2026